



Universidad Europea

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

MÁSTER DE FORMACIÓN PERMANENTE EN INTELIGENCIA ARTIFICIAL

TRABAJO FIN DE MÁSTER

**Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud.**

IVÁN HERNÁNDEZ ROLDÁN

Dirigido por

DAVID SANZ DIAZ

CURSO 2024

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



TÍTULO: Ajuste de los Modelos Largos de Lenguaje (Ej. GPT) para tareas de Named Entity Recognition (NER) específicas del dominio de la salud.

AUTOR: IVÁN HERNÁNDEZ ROLDÁN

TITULACIÓN: MÁSTER DE FORMACIÓN PERMANENTE EN INTELIGENCIA ARTIFICIAL

DIRECTOR/ES DEL PROYECTO: DAVID SANZ DÍAZ

FECHA: Julio de 2024

1. RESUMEN

El proyecto aborda el problema de adaptar modelos de lenguaje largo (LLMs) como GPT para tareas de reconocimiento de entidades nombradas (NER) en el ámbito de la salud. Dada la complejidad de extraer información relevante de grandes volúmenes de datos clínicos, se plantea la necesidad de desarrollar herramientas automatizadas para identificar y clasificar entidades médicas como enfermedades, medicamentos y síntomas con alta precisión.

El trabajo se centra en ajustar y evaluar modelos preexistentes utilizando técnicas de “fine-tuning”. Además, se implementan alternativas de NER, como GLiNER, y se desarrolla una aplicación interactiva en Streamlit para comparar el rendimiento de los modelos. Los resultados muestran que los modelos ajustados superan a los no ajustados en métricas clave. GLiNER destacó en la localización precisa de entidades gracias a su preentrenamiento especializado.

Las conclusiones indican que el “fine-tuning” y el “prompting” son estrategias efectivas para mejorar el desempeño de LLMs en tareas de NER en salud, ofreciendo una herramienta práctica para su evaluación y aplicación en contextos clínicos. Este proyecto, desarrollado sin colaboración directa con una empresa, aporta soluciones que pueden optimizar la gestión y análisis de datos en el sector sanitario.

Palabras clave: Modelos de lenguaje largo (LLMs), “Fine-tuning”, Reconocimiento de entidades nombradas (NER), Procesamiento del lenguaje natural (NLP), Salud.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



2. ABSTRACT

The project addresses the problem of adapting large language models (LLMs) like GPT for named entity recognition (NER) tasks in the healthcare domain. Given the complexity of extracting relevant information from large volumes of clinical data, there is a need to develop automated tools to accurately identify and classify medical entities such as diseases, medications, and symptoms.

The work focuses on fine-tuning and evaluating pre-existing models using fine-tuning techniques. Additionally, alternatives for NER such as GLiNER are implemented, and an interactive application in Streamlit is developed to compare model performance. The results show that fine-tuned models outperform non-fine-tuned ones in key metrics. GLiNER excelled in the precise localization of entities thanks to its specialized pretraining.

The conclusions indicate that fine-tuning and prompting are effective strategies to enhance the performance of LLMs in NER tasks in healthcare, providing a practical tool for their evaluation and application in clinical contexts. This project, developed without direct collaboration with a company, offers solutions that can optimize data management and analysis in the healthcare sector.

Keywords: Large Language Models (LLMs), Fine-tuning, Named Entity Recognition (NER), Natural Language Processing (NLP), Healthcare.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



AGRADECIMIENTOS

Quisiera expresar mi más profundo agradecimiento a todas las personas que han contribuido de alguna forma al desarrollo de este proyecto.

En primer lugar, agradezco a mi tutor por su guía y apoyo constante. Sus valiosos consejos y su disponibilidad para responder a mis dudas han sido fundamentales para llevar este trabajo a buen término.

A mi compañero de trabajo, por sus mentorías constantes y apoyo durante el proceso. Su colaboración fue crucial en momentos clave del proyecto, y su experiencia me ayudó a mejorar y superar varios desafíos.

A mi familia y amigos, por su paciencia, ánimo y comprensión a lo largo de esta etapa. Su confianza en mí me ha motivado a seguir adelante y a dar lo mejor de mí en cada paso del camino.

Finalmente, agradezco a todas las personas y comunidades que comparten su conocimiento de manera abierta y desinteresada. Los recursos, tutoriales y discusiones en línea fueron una fuente invaluable de aprendizaje e inspiración durante el desarrollo de este proyecto.

A todos, muchas gracias. Este logro no habría sido posible sin su apoyo y colaboración.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



"El comienzo de la sabiduría es llamar a las cosas por su nombre."
Confucio

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



3. TABLA RESUMEN

	DATOS
Nombre y apellidos:	Iván Hernández Roldán
Título del proyecto:	Ajuste de los Modelos Largos de Lenguaje (Ej. GPT) para tareas de Named Entity Recognition (NER) específicas del dominio de la salud.
Directores del proyecto:	David Sanz Díaz
El proyecto se ha realizado en colaboración de una empresa o a petición de una empresa:	NO
El proyecto ha implementado un producto: (esta entrada se puede marcar junto a la siguiente)	SI
El proyecto ha consistido en el desarrollo de una investigación o innovación: (esta entrada se puede marcar junto a la anterior)	NO
Objetivo general del proyecto:	Realizar un ajuste de Modelos Largos de Lenguaje para adaptar los LLM a tareas específicas de NER en el contexto de la salud.

Tabla 1: Resumen del proyecto.

4. Índice

Contenido

1. RESUMEN	3
2. ABSTRACT	4
3. TABLA RESUMEN	7
Capítulo 1. RESUMEN DEL PROYECTO	12
1.1 Contexto y justificación.....	12
1.2 Planteamiento del problema	12
1.3 Objetivos del proyecto.....	12
1.4 Resultados obtenidos	12
1.5 Estructura de la memoria	12
Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE	13
2.1 Estado del arte	13
2.2 Contexto y justificación.....	14
2.3 Planteamiento del problema	16
Capítulo 3. OBJETIVOS.....	17
3.1 Objetivos generales	17
3.2 Objetivos específicos	17
3.3 Beneficios del proyecto	18
Capítulo 4. DESARROLLO DEL PROYECTO	19
4.1 Planificación del proyecto.....	19
4.2 Descripción de la solución, metodologías y herramientas empleadas.....	21
4.2.1 Investigación.....	21
4.2.2 Selección del Conjunto de Datos.....	23
4.2.3 Desarrollo e Implementación	25
4.3 Recursos requeridos	36
4.4 Presupuesto	37
4.5 Viabilidad	38

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud



Iván Hernández Roldán

4.6	Resultados del proyecto	39
Capítulo 5.	CONCLUSIONES	41
5.1	Conclusiones del trabajo	41
5.2	Conclusiones personales	41
Capítulo 6.	FUTURAS LÍNEAS DE TRABAJO	42
6.1	Ampliación del Conjunto de Datos	42
6.2	Experimentación con Técnicas de Transfer Learning	42
6.3	Integración y Evaluación en Entornos Clínicos Reales	42
6.4	Desarrollo de un “Pipeline” de “Fine-tuning” Automatizado	43
6.5	Mejora de la Aplicación Interactiva	43
6.6	Investigación sobre la Interpretabilidad y Explicabilidad de los Modelos	43
6	REFERENCIAS	44

Índice de Figuras

Figura 1: Evaluaciones de OpenAI sobre la fiabilidad de sus modelos siguiendo esquemas JSON complejos..... 22

Figura 2: Ejemplo de texto clínico..... 26

Figura 3: Salida esperada sin preprocesar a la izquierda y salida esperada procesada a la derecha..... 26

Índice de Tablas

Tabla 1: Resumen del proyecto..... 7

Tabla 2: Cronograma del proyecto..... 21

Tabla 3: Resumen de estadísticas por modelo..... 32

Tabla 4: Presupuesto desglosado del proyecto. 37

Capítulo 1. RESUMEN DEL PROYECTO

1.1 Contexto y justificación

Este proyecto se centra en aplicar modelos de lenguaje largo (LLMs) para el reconocimiento de entidades nombradas o NER (“Named Entity Recognition”) en el ámbito de la salud. Ante la gran cantidad de datos clínicos, se busca mejorar la identificación automática de entidades médicas como enfermedades, medicamentos y síntomas, optimizando así la gestión de información médica.

1.2 Planteamiento del problema

Se aborda el reto de adaptar LLMs como GPT (“Generative Pre-trained Transformer”) para tareas de NER específicas en salud, dado que los modelos generales no alcanzan la precisión necesaria. El proyecto investiga cómo el “fine-tuning” puede mejorar la precisión de estos modelos para identificar entidades médicas.

1.3 Objetivos del proyecto

El objetivo principal es ajustar y evaluar un LLM para NER en salud. Esto incluye preparar datos clínicos, realizar el “fine-tuning” del modelo, implementar alternativas como GLiNER [1], y desarrollar una aplicación interactiva para comparar los modelos, mejorando así la precisión en la identificación de entidades médicas.

1.4 Resultados obtenidos

Los modelos ajustados superaron a los no ajustados, destacando el modelo GPT-4o mini [2], ajustado con un conjunto etiquetado de 1000 muestras, con una precisión alrededor del 85%. La aplicación desarrollada en Streamlit [3] facilita la comparación de modelos, y GLiNER demostró ser efectivo en la ubicación precisa de entidades gracias a su preentrenamiento. El código de este trabajo ha sido subido al repositorio de Github [4].

1.5 Estructura de la memoria

- **Capítulo 2:** Detalla el contexto y la justificación del proyecto.
- **Capítulo 3:** Plantea el problema y los objetivos que se persiguen.
- **Capítulo 4:** Describe la metodología y herramientas utilizadas.
- **Capítulo 5:** Presenta y discute los resultados obtenidos.
- **Capítulo 6:** Conclusiones y futuras líneas de trabajo.

Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

El proyecto se centra en el uso y ajuste de Modelos Largos de Lenguaje, específicamente para abordar tareas de NER dentro del dominio de la salud, un ámbito que requiere alta precisión y sensibilidad debido a la naturaleza crítica de la información que se maneja. Este tipo de tareas NER consiste en identificar y clasificar entidades relevantes como nombres de personas, organizaciones, ubicaciones, fechas, cantidades, y otras categorías predefinidas dentro de un texto.

En el dominio de la salud, las tareas de NER se centran en la identificación de entidades médicas como enfermedades, síntomas, medicamentos, procedimientos y otros conceptos clínicos. La extracción precisa de estas entidades es crucial para aplicaciones como el análisis de registros médicos, la extracción de conocimiento para la investigación clínica, y la mejora de sistemas de atención al paciente, ya que permite una mejor comprensión y organización de la información médica contenida en grandes volúmenes de texto no estructurado.

El “fine-tuning” de los modelos, también conocido como “fine-tuning”, es fundamental en este contexto, ya que permite especializar un modelo general en un dominio específico, mejorando su rendimiento en tareas concretas.

2.1 Estado del arte

En el ámbito del procesamiento del lenguaje natural o “natural language processing” (NLP), los modelos de lenguaje como GPT han mostrado un rendimiento excepcional en una variedad de tareas lingüísticas generales. Sin embargo, su aplicación en dominios específicos como el de la salud presenta retos adicionales. La literatura actual sugiere que el “fine-tuning” de estos modelos en conjuntos de datos especializados mejora su precisión en tareas específicas, como las tareas NER en medicina.

Entre los enfoques más avanzados en el campo del NER en la salud, destacan modelos ajustados de tipo BERT (“Bidirectional Encoder Representations from Transformers”) como “BioBERT” [5] y “ClinicalBERT” [6], que han sido preentrenados en grandes corpus biomédicos y clínicos. Estos modelos han demostrado un rendimiento superior en tareas NER cuando se comparan con modelos de propósito general, sugiriendo la importancia del preentrenamiento y “fine-tuning” en el dominio específico. Sin embargo, aunque estos modelos especializados son altamente efectivos, los avances recientes en modelos de propósito general como GPT-4 han abierto nuevas vías de investigación sobre si un “fine-tuning” mínimo en un corpus específico podría igualar o superar el rendimiento de estos modelos preentrenados.

Además, los enfoques de aprendizaje “zero-shot” en los que se entrena un modelo de IA para reconocer y categorizar objetos o conceptos sin haber visto previamente ningún ejemplo de esas

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



categorías o conceptos, como el utilizado en GLINER [1], han introducido nuevas capacidades, permitiendo que los modelos realicen tareas NER sin requerir ajustes finos específicos para cada dominio. Esto es particularmente relevante en escenarios donde los datos anotados son limitados o costosos de obtener, como puede ocurrir en el campo de la medicina.

Por otro lado, modelos como GPT-4o [7] y Claude 3.5 Sonnet [8], desarrollados por OpenAI y Anthropic respectivamente, representan la frontera tecnológica en el uso de modelos grandes y preentrenados, maximizando tanto la comprensión contextual como la capacidad de realizar tareas especializadas sin comprometer la precisión en dominios complejos como el de la salud.

2.2 Contexto y justificación

La motivación de este proyecto surge de la creciente necesidad de mejorar las herramientas de procesamiento del lenguaje natural en el dominio de la salud, un campo donde la precisión y la capacidad para identificar entidades médicas de manera automática son cruciales. En un entorno donde la cantidad de datos clínicos y biomédicos crece exponencialmente, contar con modelos que puedan reconocer entidades específicas como enfermedades, medicamentos y procedimientos con alta precisión puede facilitar tareas de investigación, diagnóstico asistido y gestión de la información clínica. La automatización precisa del reconocimiento de entidades médicas puede reducir errores, aumentar la eficiencia en el manejo de datos y ofrecer un soporte invaluable para los profesionales de la salud en la toma de decisiones.

El “fine-tuning” de modelos de lenguaje, como GPT, en un contexto de NER en el ámbito de la salud se presenta como una solución prometedora para enfrentar estos desafíos. Sin embargo, hasta la fecha, gran parte de los avances en este campo se han centrado en modelos específicos como BioBERT o ClinicalBERT, mientras que el potencial de modelos de propósito general ajustados finamente para este dominio aún está por explorarse en profundidad.

Este proyecto se justifica tanto por el vacío existente en la literatura como por el impacto potencial que podría tener en la práctica clínica y en la investigación biomédica. Mientras que los modelos específicos preentrenados han demostrado ser efectivos, no se ha investigado exhaustivamente cómo los modelos de propósito general como GPT, cuando se ajustan con una cantidad limitada de datos, pueden ofrecer una alternativa competitiva, o incluso superior, en el ámbito de la salud. El desarrollo de herramientas más eficientes y flexibles es de particular interés en este campo, donde la obtención de datos anotados y especializados puede ser costosa y difícil de escalar.

Por ejemplo, esta tecnología podría aplicarse en los siguientes casos:

- **Monitorear brotes y epidemias:** Detectar aumentos inusuales en el diagnóstico de determinadas enfermedades o la aparición de síntomas similares en un grupo de

pacientes podría ayudar a identificar brotes o emergencias sanitarias de manera temprana, permitiendo una respuesta rápida y efectiva.

- **Evaluar el consumo de medicamentos:** Analizar el consumo de medicamentos dentro de una población ayudaría a detectar patrones de uso excesivo o inapropiado, identificando problemas como la prescripción excesiva de antibióticos, que podría conducir a la resistencia bacteriana, o el abuso de medicamentos controlados.
- **Estudiar la evolución de síntomas:** A través de la extracción automatizada de datos relacionados con síntomas, sería posible rastrear la evolución de condiciones crónicas o emergentes en una comunidad. Este tipo de análisis podría ayudar a identificar cambios en la gravedad o frecuencia de los síntomas, y servir como base para intervenciones clínicas o de salud pública.
- **Planificación y asignación de recursos:** Al analizar las tendencias de enfermedades y medicamentos, los hospitales y sistemas de salud podrían optimizar la planificación de recursos, como la distribución de personal, camas hospitalarias y suministro de medicamentos, asegurando una respuesta eficiente ante cambios en las demandas sanitarias.
- **Investigación en salud pública:** La información agregada a partir de los registros médicos podría servir de base para estudios epidemiológicos, permitiendo a los investigadores evaluar factores de riesgo, eficacia de tratamientos y evolución de enfermedades en diferentes poblaciones.

Además, este proyecto aportará varias contribuciones clave al campo de estudio:

- **Evaluación comparativa de modelos ajustados y no ajustados:** El proyecto comparará de manera sistemática modelos ajustados y no ajustados en tareas de NER, proporcionando una visión clara del impacto que tiene el “fine-tuning” en conjuntos de datos limitados y específicos del dominio de la salud.
- **Eficiencia en el uso de datos:** Dado que el proyecto evaluará el rendimiento de los modelos con diferentes tamaños de conjuntos de datos, contribuirá a comprender hasta qué punto es necesario contar con grandes volúmenes de datos especializados para obtener resultados competitivos.
- **Alternativas a los modelos preentrenados específicos:** Este trabajo abrirá el debate sobre si es posible o no reemplazar, en algunos escenarios, modelos especializados en tareas NER como GLINER con modelos ajustados finamente como GPT-4, ofreciendo mayor flexibilidad y aplicabilidad en diferentes dominios con un esfuerzo mínimo.
- **Exploración de enfoques “zero-shot”:** Con la inclusión de modelos como GLINER, el proyecto también ofrecerá una perspectiva sobre la viabilidad de usar modelos de

aprendizaje “zero-shot” en entornos donde los datos anotados son escasos, algo muy relevante en la práctica clínica.

Este trabajo no solo ofrecerá una evaluación exhaustiva de diferentes enfoques y modelos para NER en salud, sino que también puede sentar las bases para futuras aplicaciones en sistemas de soporte a la decisión clínica y automatización de tareas administrativas y de investigación en el sector salud.

2.3 Planteamiento del problema

El planteamiento del problema de este trabajo se centra en la necesidad de mejorar las herramientas de NLP para NER en el dominio de la salud. Aunque los avances en modelos de lenguaje, como BioBERT y ClinicalBERT, han demostrado que los modelos preentrenados en corpus biomédicos son eficaces para tareas específicas, el “fine-tuning” de modelos más generales como GPT en tareas NER especializadas aún no ha sido explorado a fondo. Esta laguna representa una oportunidad significativa para investigar si modelos de propósito general ajustados con conjuntos de datos limitados pueden ofrecer una alternativa competitiva en términos de rendimiento y flexibilidad en comparación con los modelos preentrenados.

El análisis del estado del arte revela que la personalización de los modelos de lenguaje en dominios específicos ha sido crucial para mejorar la precisión en la identificación de entidades médicas. Sin embargo, la dependencia de grandes volúmenes de datos especializados y anotados plantea un desafío en términos de escalabilidad y aplicabilidad a diferentes contextos clínicos. Adicionalmente, los enfoques tradicionales no permiten evaluar adecuadamente el uso de datos más limitados o la viabilidad de modelos “zero-shot”, que podrían proporcionar soluciones eficientes en escenarios con escasez de datos.

Este proyecto se plantea como una respuesta directa a esta problemática: la falta de conocimiento sobre el rendimiento de modelos generales ajustados finamente en comparación con los modelos preentrenados específicos del dominio de la salud. A través de la evaluación de diferentes alternativas de “fine-tuning” de GPT, se busca analizar si un modelo de propósito general, ajustado con conjuntos de datos más pequeños, puede igualar o incluso superar el rendimiento de los modelos especializados en la extracción de entidades en el contexto médico.

Asimismo, se pretende explorar la capacidad de modelos NER avanzados, como GLINER, para proporcionar soluciones innovadoras en escenarios donde los datos son escasos o difíciles de obtener, como es común en muchos sistemas de salud. La resolución de esta problemática permitirá avanzar en el desarrollo de soluciones más flexibles y eficientes para la automatización de tareas de NER en salud, contribuyendo a mejorar la gestión de datos clínicos, la investigación biomédica y la toma de decisiones médicas.

Capítulo 3. OBJETIVOS

3.1 Objetivos generales

El objetivo general del presente trabajo consiste en ajustar y evaluar un modelo LLM, como GPT, para realizar tareas de NER dentro del ámbito de la salud. El proyecto buscará adaptar el modelo a textos clínicos, de manera que sea capaz de identificar y clasificar automáticamente entidades médicas relevantes, como enfermedades, síntomas, medicamentos y tratamientos. A través de este proceso, se pretende optimizar el modelo para que pueda ser utilizado en aplicaciones clínicas, mejorando la gestión de datos médicos y facilitando el análisis de información de manera automatizada. El proyecto se enfocará en comparar el rendimiento del modelo ajustado con otros enfoques existentes para determinar su efectividad en este contexto especializado.

3.2 Objetivos específicos

Los objetivos concretos del presente trabajo, relacionados con el objetivo general de ajustar y evaluar un LLM para tareas de NER en el ámbito de la salud, son los siguientes:

- **Recopilar** un conjunto de datos clínicos que incluya anotaciones de entidades médicas relevantes, como enfermedades, síntomas, medicamentos y tratamientos.
- **Preprocesar** los datos clínicos para garantizar su calidad y adecuación al proceso de ajuste del modelo, incluyendo la limpieza de textos, etiquetado y normalización de términos médicos.
- **Ajustar** un modelo GPT preentrenado mediante técnicas de aprendizaje supervisado, utilizando los datos clínicos recopilados para especializar el modelo en el reconocimiento de entidades médicas.
- **Experimentar** con diferentes configuraciones de “fine-tuning”, variando el tamaño y el contenido del conjunto de datos, con el objetivo de optimizar su rendimiento.
- **Evaluar** en términos de precisión, “recall” y “F1-score” el rendimiento de diferentes alternativas a la hora de abordar una tarea NER en el ámbito de la salud.
- **Comparar** el modelo ajustado con enfoques alternativos, incluyendo modelos sin “fine-tuning” y modelos de tipo BERT especializados en NER, como GLINER, para identificar las ventajas y desventajas de cada una de las alternativas.
- **Validar** la efectividad del modelo en diferentes casos de uso dentro del dominio clínico, como la identificación de enfermedades o la clasificación de medicamentos, para comprobar su aplicabilidad en entornos reales. Para ello, el repositorio de este trabajo [4] contiene una aplicación que permite comprobar a cualquier persona cómo funcionan

las diferentes alternativas a la hora de realizar NER sobre un texto de entrada de su elección.

- **Documentar** los resultados obtenidos y las conclusiones del proceso en la presente memoria, destacando las implicaciones del “fine-tuning” en modelos de lenguaje general aplicados al ámbito de la salud.

Estos objetivos permitirán obtener un análisis completo y detallado del rendimiento de los modelos ajustados y su potencial aplicación en tareas clínicas automatizadas.

3.3 Beneficios del proyecto

El proyecto aporta beneficios significativos tanto en el campo de la investigación como en aplicaciones prácticas dentro del dominio de la salud. Al cumplir con los objetivos planteados, este trabajo permitirá optimizar el uso de LLM, como GPT, en tareas de NER específicamente en textos clínicos, lo que mejorará la precisión y eficiencia en el procesamiento de información médica.

Uno de los principales beneficios es la capacidad de automatizar la identificación y clasificación de entidades médicas relevantes, como enfermedades, síntomas y tratamientos, en grandes volúmenes de datos clínicos. Esto puede reducir considerablemente el tiempo y esfuerzo necesario para analizar estos textos, facilitando tareas como la gestión de registros médicos electrónicos, la investigación clínica y la farmacovigilancia. Al mejorar el acceso y procesamiento de esta información crítica, se pueden tomar decisiones más rápidas y basadas en datos, lo que impacta positivamente en la calidad de la atención médica y en la seguridad del paciente.

Además, el proyecto proporciona una evaluación comparativa entre modelos ajustados y no ajustados, así como con otros enfoques especializados en NER, lo que permitirá identificar los enfoques más eficientes y efectivos. Esta comparación contribuirá al conocimiento actual sobre cómo ajustar modelos generales como GPT a dominios específicos, ofreciendo soluciones más flexibles y escalables en situaciones donde los datos anotados especializados son limitados.

Finalmente, el proyecto amplía las posibilidades de aplicar modelos de lenguaje en el ámbito clínico, abriendo la puerta a herramientas de soporte a la toma de decisiones, análisis epidemiológico automatizado y mejoras en la gestión de datos médicos. Todo ello contribuye a la modernización y optimización de los procesos en los sistemas de salud, facilitando la innovación en tecnologías que mejoran el bienestar y la atención de los pacientes.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán

Capítulo 4. DESARROLLO DEL PROYECTO

4.1 Planificación del proyecto

A lo largo de este Trabajo de Fin de Máster (TFM), se llevaron a cabo una serie de actividades clave que abarcan desde la investigación inicial hasta el desarrollo y evaluación de modelos, así como la documentación final. El siguiente es un cronograma detallado de estas actividades, junto con su descripción y el esfuerzo empleado en cada una.

Fase	Actividad	Descripción	Esfuerzo (semanas)
Investigación	Investigación de la Metodología NER (Estado del Arte)	Se realizó un estudio exhaustivo de la literatura existente sobre NER en el ámbito de la salud, abarcando las técnicas más avanzadas y los modelos actuales de referencia.	3
	Investigación sobre “Fine-tuning”	Investigación sobre las técnicas de “fine-tuning” para modelos de lenguaje largo, con foco en cómo adaptar estos modelos a tareas específicas del NER.	2
	Investigación sobre “Fine-tuning” para NER	Se profundizó en las metodologías para aplicar “fine-tuning” específicamente en tareas de NER, incluyendo la revisión de casos de éxito y limitaciones de este enfoque.	2
Selección del Conjunto de Datos o “Dataset”	Selección de “Dataset” para “Fine-tuning”	Proceso de búsqueda, evaluación y selección de conjuntos de datos clínicos que contengan anotaciones de entidades médicas, asegurando su relevancia y calidad para el “fine-tuning”.	1

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



Desarrollo e Implementación	Preprocesamiento del "Dataset"	Limpieza y preparación del conjunto de datos seleccionado, incluyendo la normalización y etiquetado de términos médicos para su uso en el entrenamiento del modelo.	1
	"Fine-tuning" del Modelo	Implementación del "fine-tuning" del modelo GPT con los datos preprocesados, afinando el conjunto de datos del entrenamiento y maximizando el rendimiento para NER en salud.	3
	Implementación de Alternativas NER	Desarrollo e implementación de alternativas para NER, como modelos "zero-shot" y basados en BERT, para establecer una base comparativa con el modelo ajustado.	2
	Obtención de Resultados y Evaluación	Realización de pruebas, evaluación del rendimiento de los modelos ajustados y alternativos, y análisis de métricas como precisión, "recall" y "F1-score".	2
	Creación de App en Streamlit	Desarrollo de una demo del proyecto en Streamlit que permite a los usuarios interactuar y probar las diferentes alternativas NER analizadas en el proyecto.	1
	"Dockerización"	Creación de un contenedor Docker [9] para facilitar el despliegue y uso de la aplicación y los modelos desarrollados en diferentes entornos.	1

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



Documentación	Redacción de la Memoria	Documentación completa del proceso, incluyendo la metodología, resultados y conclusiones del TFM.	3
----------------------	-------------------------	---	---

Tabla 2: Cronograma del proyecto.

4.2 Descripción de la solución, metodologías y herramientas empleadas

4.2.1 Investigación

El primer paso en el desarrollo de este proyecto fue llevar a cabo un estudio exhaustivo de la literatura existente sobre NER en el ámbito de la salud. Este análisis incluyó una revisión detallada de las técnicas más avanzadas y los modelos actuales de referencia en el campo, con el objetivo de comprender el estado del arte y las tendencias actuales en el uso de modelos de lenguaje para tareas de NER.

Se investigaron diferentes enfoques, como el uso de modelos basados en transformadores, incluyendo BERT y sus variantes especializadas en el dominio biomédico, como BioBERT y ClinicalBERT. Además, se examinó la aplicación de LLMs como GPT en este contexto.

El primer enfoque estudiado, dado que es el tema central del trabajo, fue la aplicación del "fine-tuning" a los Modelos Largos de Lenguaje (LLMs) para tareas específicas de NER. Se inició con la investigación de los diferentes métodos de "fine-tuning", que se encuentran bien resumidos en [10].

Dado que el objetivo del proyecto es mejorar la calidad en la tarea de NER aplicada al ámbito de la salud, se decidió centrar el análisis en los LLMs más avanzados disponibles actualmente. Estos modelos se pueden consultar en el ranking conocido como "Chatbot Arena Leaderboard" ofrecido por LMSYS [11], y se seleccionaron aquellos que permiten la aplicación de "fine-tuning". Por este motivo, se optó por los modelos de OpenAI, específicamente GPT-4o [7] y GPT-4o mini [2].

Entre las diversas opciones de "fine-tuning" disponibles, se siguieron las recomendaciones de OpenAI para ajustar sus modelos, que consisten en una estrategia de "fine-tuning" supervisado. Este enfoque es significativamente diferente al utilizado para ajustar los modelos BERT en tareas de "fine-tuning" [12]. Por esta razón, se decidió no considerar los modelos BioBERT y ClinicalBERT como alternativas para la comparación.

Uno de los aspectos más importantes de la investigación inicial sobre el "fine-tuning" de LLMs para tareas de NER fue determinar la forma adecuada que debería tener el conjunto de datos etiquetado para entrenar el modelo. OpenAI ofrece ejemplos en [13] que muestran cómo debe formatearse el "fine-tuning" de sus modelos. Estas muestras incluyen un mensaje del sistema, que indica cómo debe comportarse el modelo, una instrucción o "prompt" del usuario, y la respuesta del modelo o asistente asociada a dicha instrucción.

En las tareas de NER, es esencial identificar cuatro elementos para cada palabra en el texto: si pertenece a un tipo de entidad previamente definido, la cadena de texto reconocida como una entidad, la posición inicial de esa cadena en el texto y la posición final.

Estos requisitos sugieren el uso de una función innovadora de los modelos de lenguaje conocida como "structured output" [14]. Esta funcionalidad permite obtener la respuesta del modelo en un formato JSON ("JavaScript Object Notation") predefinido por el usuario.

El reciente avance de OpenAI, presentado el 6 de agosto de 2024 con su modelo 'gpt-4o-2024-08-06', refuerza la idea de utilizar "structured output". Este modelo ha demostrado una alta eficacia al seguir esquemas JSON complejos, alcanzando una precisión del 100% con salidas estructuradas estrictas, como se muestra en la figura 1. Esto es fundamental para aplicaciones que requieren respuestas altamente estructuradas y precisas, como es el caso del presente trabajo.




Figura 1: Evaluaciones de OpenAI sobre la fiabilidad de sus modelos siguiendo esquemas JSON complejos.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



Afortunadamente para el desarrollo de este trabajo, OpenAI también proporciona ejemplos específicos en [15] para realizar "fine-tuning" de modelos de manera que se adapten a responder con "structured output".

Así, la forma de identificar las cuatro variables mencionadas previamente en este estudio ha sido utilizando un esquema JSON adecuado y aprovechando la funcionalidad de "structured output".

Otro aspecto crucial en esta primera fase es la selección de las entidades que se desean reconocer en textos relacionados con el ámbito de la salud. Dado que esta elección depende del conjunto de datos utilizado en este trabajo, se abordará más a fondo en la subsección 4.2.2.

Finalmente, la incertidumbre sobre el tipo de entidades a reconocer motivó la exploración de modelos alternativos, como los modelos "zero-shot", que no requieren entrenamiento adicional con datos específicos del dominio para realizar tareas de NER. Por esta razón, se incluyó en la comparación con los LLM ajustados al modelo conocido como GLiNER, ya que este no depende del tipo de entidades seleccionadas para llevar a cabo las tareas de NER.

GLiNER [1] es un modelo de Reconocimiento de Entidades Nombradas (NER) capaz de identificar cualquier tipo de entidad utilizando un codificador transformador bidireccional, similar a BERT. Ofrece una alternativa "zero-shot" práctica a los modelos NER tradicionales, que están limitados a entidades predefinidas, y a los Modelos de Lenguaje Grandes (LLMs) que, a pesar de su flexibilidad, son costosos y grandes para escenarios con recursos limitados.

4.2.2 Selección del Conjunto de Datos

Para realizar "fine-tuning" de Modelos Largos de Lenguaje en tareas de NER, es fundamental contar con un conjunto de datos etiquetado que proporcione ejemplos claros sobre cómo identificar y clasificar las entidades relevantes. Este conjunto de datos debe contener texto relacionado con la salud, donde las entidades nombradas estén claramente definidas, incluyendo su posición en el texto y su tipo asociado.

Dada la naturaleza médica del proyecto, se buscó específicamente un conjunto de datos que satisficiera varios requisitos esenciales:

- **Texto relacionado con la salud en plano:** El "dataset" debe contener textos clínicos o médico, no tokenizado, para asegurar la coherencia contextual en la identificación de las entidades.
- **Cadenas de texto reconocidas (no tokens):** Las entidades debían ser cadenas completas y significativas, no simplemente fragmentos o tokens, lo que permite al modelo aprender a identificar entidades completas en contexto.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



- **Tipo de entidad asociada:** Cada entidad reconocida debía tener una etiqueta que identificara su tipo (por ejemplo, enfermedad, medicamento, síntoma, etc.).
- **Posición inicial y final de la entidad:** La anotación del dataset debía incluir la localización precisa de cada entidad dentro del texto, lo cual es crucial para tareas de NER.

Tras varios días de búsqueda y evaluación, se consideraron las siguientes opciones:

- **The 2014 i2b2/UTHealth Corpus [16]:**

Este conjunto de datos parecía prometedor debido a su enfoque en la desidentificación y etiquetado de información clínica. Sin embargo, durante el proceso de revisión, se descubrió que el acceso a este “dataset” está restringido actualmente, según la información encontrada en [17]. Esto limitó la posibilidad de utilizarlo para el presente trabajo, ya que no se pudo obtener una copia para su uso y experimentación.

- **CADEC de CSIRO [18]:**

El conjunto de datos CADEC (“Corpus of Adverse Drug Event Annotations”) de CSIRO fue otra opción evaluada y resultó ser adecuada para las necesidades del proyecto. Este “dataset” contiene anotaciones de texto clínico con etiquetas como “ADR”, “Disease”, “Drug”, “Finding” o “Symptom”, que son fundamentales para las tareas de NER en el ámbito de la salud. Las etiquetas se interpretan de la siguiente manera:

- **ADR (“Adverse Drug Reaction”):** Identifica reacciones adversas a medicamentos, proporcionando información crítica para la farmacovigilancia. Ejemplos: "Náusea", "Dolor de cabeza", "Erupción cutánea".
- **“Disease”:** Indica enfermedades o condiciones médicas, ayudando a la identificación de diagnósticos en textos clínicos. Ejemplos: "Diabetes", "Hipertensión", "Cáncer de mama".
- **“Drug”:** Marca menciones de medicamentos, tanto por nombre comercial como genérico, facilitando el seguimiento de la medicación. Ejemplos: "Paracetamol", "Ibuprofeno", "Aspirina".
- **“Finding”:** Anota hallazgos clínicos, que pueden ser observaciones importantes o resultados de pruebas médicas. Ejemplos: "Inflamación", "Lesión", "Elevación de la presión arterial".
- **“Symptom”:** Señala los síntomas reportados por los pacientes, fundamentales para la comprensión de la condición clínica. Ejemplos: "Dolor", "Fatiga", "Fiebre".

El conjunto de datos CADEC es altamente relevante para el desarrollo de modelos de NER orientados a la extracción de información médica, especialmente en la identificación de efectos adversos de medicamentos y otros aspectos clínicos. Su uso

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



permite que los modelos aprendan a identificar y clasificar de manera precisa las entidades médicas en textos no estructurados.

- **Generación de un Nuevo Conjunto de Datos Sintético**

Otra opción considerada fue la generación de un nuevo conjunto de datos sintético utilizando un LLM, concretamente GPT-4o. Este enfoque permitiría crear ejemplos personalizados y adaptados a las necesidades específicas del proyecto. Sin embargo, la parte negativa de este método radica en que los datos generados pueden carecer de la riqueza y complejidad de los datos clínicos reales, lo que podría limitar la capacidad del modelo para generalizar y aplicarse a textos clínicos auténticos. Además, existe el riesgo de introducir sesgos del modelo generador en los datos sintéticos, lo que podría afectar negativamente el rendimiento del modelo ajustado.

En resumen, la selección del conjunto de datos fue un paso crucial para el proyecto. Después de evaluar las opciones disponibles y considerar los requisitos del proyecto, se optó por utilizar el “dataset” CADEC de CSIRO debido a su relevancia y detalle en las anotaciones, proporcionando una base sólida para el “fine-tuning” del modelo en tareas de NER en el ámbito de la salud.

Por lo tanto, se decidió que las entidades a reconocer en este trabajo serían reacciones adversas a medicamentos, enfermedades o condiciones médicas, medicamentos, hallazgos clínicos y síntomas reportados por los pacientes.

4.2.3 Desarrollo e Implementación

Toda la información explicada en esta sección se encuentra representada en el repositorio de Github del trabajo [4]. Se recomienda revisarlo para una comprensión completa del contenido.

Preprocesamiento del Dataset

El conjunto de datos CADEC de CSIRO está dividido en dos carpetas principales: una llamada “text”, que contiene los textos clínicos en formato plano, y otra denominada “original”, que incluye las anotaciones en su formato original. Existen otras carpetas con diferentes formatos de anotaciones, pero estas no son relevantes para este caso, ya que anotan las entidades mediante códigos en lugar de etiquetas de texto.

Para cada texto clínico en la carpeta “text”, existe un archivo correspondiente en la carpeta “original” que contiene las entidades reconocidas. El texto clínico no requiere modificaciones, ya que será la entrada del modelo y se combinará con el “prompt” del usuario. Sin embargo, el archivo de entidades reconocidas necesita ser preprocesado para convertirlo en la salida esperada del modelo.

I feel a bit drowsy & have a little blurred vision, so far
no gastric problems.
I've been on Arthrotec 50 for over 10 years on and off, only
taking it when I needed it.
Due to my arthritis getting progressively worse, to the
point where I am in tears with the agony, gp's started me on
75 twice a day and I have to take it.
every day for the next month to see how I get on, here goes.
So far its been very good, pains almost gone, but I feel a
bit weird, didn't have that when on 50.

Figura 2: Ejemplo de texto clínico.

Para ilustrar el preprocesamiento realizado en este trabajo, se toma como ejemplo el fragmento de texto mostrado en la Figura 2. En la Figura 3, se presentan dos capturas que reflejan el contenido del archivo de las entidades reconocidas: una muestra la salida esperada sin preprocesar y la otra muestra la salida esperada después del preprocesamiento.

```
T1 ADR 9 19 bit drowsy
#1 AnnotatorNotes T1 Drowsy
T2 ADR 29 50 little blurred vision
#2 AnnotatorNotes T2 Blurred Vision
T3 Drug 93 102 Arthrotec
T5 Disease 179 188 arthritis
T6 Symptom 260 265 agony
T4 ADR 62 78 gastric problems
T7 Symptom 412 417 pains
T8 ADR 437 453 feel a bit weird
#8 AnnotatorNotes T7 Implies a previous symptom of pain.
```

```
{
  "adverse_drug_reactions": [
    ("bit drowsy", 9, 19),
    ("little blurred vision", 29, 50),
    ("gastric problems", 62, 78),
    ("feel a bit weird", 437, 453)
  ],
  "diseases_or_medical_conditions": [
    ("arthritis", 179, 188)
  ],
  "medications": [
    ("Arthrotec", 93, 102)
  ],
  "clinical_findings": [],
  "symptoms_experienced_by_patients": [
    ("agony", 260, 265), ("pains", 412, 417)
  ]
}
```

Figura 3: Salida esperada sin preprocesar a la izquierda y salida esperada procesada a la derecha.

El descrito preprocesamiento se encuentra implementado en la carpeta "src/lib/preprocessing" del repositorio del trabajo [4].

Una vez preprocesadas todas las salidas esperadas, estas se integraron con el mensaje del sistema y el "prompt" del usuario para formar las muestras del conjunto de datos etiquetado, siguiendo el formato sugerido por OpenAI en [15].

Finalmente, dado que los textos clínicos provienen de distintas fuentes, como se puede deducir por el nombre de los archivos, se decidió separar todas las muestras en diferentes conjuntos de datos etiquetados según el origen del texto. Así, se almacenaron tres conjuntos de datos en la carpeta "resources/fine_tuning" del repositorio [4].

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



“Fine-tuning” del Modelo

Inicialmente, se intentó realizar el “fine-tuning” de los modelos a través de la API (“Application Programming Interface”) de OpenAI, tal como se describe en [19]. Sin embargo, se encontró un obstáculo: el “fine-tuning” a través de la API está restringido a usuarios con un nivel o “tier” 4 o superior. Para alcanzar este nivel, es necesario haber acumulado un gasto de al menos 250 dólares mediante el uso de la API, un requisito que el autor de este trabajo no había cumplido.

Afortunadamente, OpenAI ofrece la posibilidad de realizar el ajuste a través de la interfaz de usuario, conocida como “fine-tuning UI” [20].

La ventaja de utilizar esta interfaz es su facilidad de uso y accesibilidad. La “fine-tuning UI” proporciona un entorno amigable donde se puede cargar el conjunto de datos y configurar los parámetros del “fine-tuning” sin necesidad de escribir código adicional o interactuar directamente con la API. Esto simplifica enormemente el proceso para usuarios que no tienen un nivel avanzado en programación o que desean realizar el ajuste de manera rápida y eficiente. Además, la interfaz guía al usuario a través de los pasos necesarios para completar el “fine-tuning”, ofreciendo una experiencia más estructurada y reduciendo el riesgo de errores que podrían ocurrir al configurar manualmente el proceso vía API.

La desventaja, sin embargo, es la limitación en cuanto a la personalización y flexibilidad. Aparte de la ausencia de las opciones avanzadas que estarían disponibles si se realizara el ajuste directamente a través de la API, uno de los principales inconvenientes es la imposibilidad de automatizar los procesos de “fine-tuning”. Cuando se realiza el ajuste a través de la API, es posible escribir scripts que automaticen completamente el proceso, lo que permite ejecutar múltiples experimentos, realizar ajustes iterativos o programar “fine-tuning” en lotes de manera eficiente. Esta capacidad de automatización es crucial cuando se desea experimentar con diferentes configuraciones, evaluar el impacto de cambios específicos en los hiperparámetros o integrar el proceso de “fine-tuning” en una secuencia de procesos de desarrollo más amplia.

A pesar de las limitaciones, se logró alcanzar el resultado deseado. Finalmente, se llevó a cabo el “fine-tuning” de los modelos GPT-4o [7] y GPT-4o mini [2] utilizando conjuntos de datos de distintos tamaños. OpenAI recomienda usar un conjunto de datos con aproximadamente 100 muestras para observar mejoras significativas en las respuestas del modelo.

En este trabajo, también se decidió comparar las respuestas de ambos modelos de OpenAI ajustados con dos conjuntos de datos diferentes: uno con 100 muestras, siguiendo la recomendación de OpenAI, y otro con 1000 muestras.

Curiosamente, dos de los subconjuntos de datos en los que se dividió el conjunto original durante el preprocesamiento, según la fuente de los textos clínicos, tienen tamaños muy cercanos a 100 y 1000 muestras. Por lo tanto, cada proceso de ajuste de los LLMs se realizó utilizando una única fuente de textos clínicos. El riesgo de sobreajuste no fue una preocupación significativa, ya que los textos presentan una variabilidad muy similar entre las distintas fuentes.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



Además, la validación del posible sobreajuste, como se detalla en la subsección ["Obtención de Resultados y Evaluación"], se realizó con un conjunto de datos compuesto por mezclas de diferentes orígenes.

En definitiva, las alternativas de LLMs ajustados para NER evaluadas en este trabajo son cuatro. El conjunto completo de estas alternativas se describe con mayor detalle en la siguiente subsección.

Implementación de Alternativas NER

En base a lo mencionado en la anterior subsección, las alternativas propuestas para NER que representan el "fine-tuning" de LLMs son las siguientes:

- **GPT-4o ajustado con un conjunto de datos de 100 muestras.** En el código del repositorio se identifica como "fine_tuned_gpt_4o".
- **GPT-4o ajustado con un conjunto de datos de 1000 muestras.** En el código del repositorio se identifica como "fine_tuned_gpt_4o_v2".
- **GPT-4o mini ajustado con un conjunto de datos de 100 muestras.** En el código del repositorio se identifica como "fine_tuned_gpt_4o_mini".
- **GPT-4o mini ajustado con un conjunto de datos de 1000 muestras.** En el código del repositorio se identifica como "fine_tuned_gpt_4o_mini_v2".

La implementación de este tipo de alternativas sigue las instrucciones ofrecidas por OpenAI en [15].

El resto de las alternativas se pueden clasificar en dos grupos. El primer grupo consiste en los LLMs sin ajustar, que intentan abordar la tarea de NER sin ningún "fine-tuning" previo. Estos modelos representan el estado del arte según [11]:

- **GPT-4o sin ajustar.** En el código del repositorio se identifica como "gpt_4o".
- **GPT-4o mini sin ajustar.** En el código del repositorio se identifica como "gpt_4o_mini".
- **Claude 3.5 Sonnet [8] sin ajustar.** En el código del repositorio se identifica como "sonnet_35".

En este caso, la implementación de estos modelos sin "fine-tuning" se llevó a cabo utilizando la funcionalidad "structured output" de LangChain [21]. LangChain ofrece la ventaja de permitir la modificación del LLM utilizado con un simple cambio en la configuración, sin necesidad de alterar la llamada a la API del proveedor. Esto se debe a que LangChain se encarga de adaptar automáticamente la llamada según el proveedor seleccionado.

Esta característica es sumamente útil para la reusabilidad del código, ya que permite cambiar entre diferentes modelos y proveedores de LLMs sin tener que reescribir o ajustar el código que interactúa con la API. Esto facilita la experimentación con distintos modelos y proveedores, optimizando el flujo de trabajo y reduciendo el tiempo necesario para implementar y probar diferentes soluciones. Además, LangChain simplifica la ampliación del proyecto, permitiendo integrar fácilmente nuevos LLMs a medida que se desarrollan o se requiere probar modelos adicionales, lo que hace que el proceso sea más eficiente y escalable.

Además del uso de LangChain, se implementaron técnicas de “prompting” para mejorar la calidad de las respuestas generadas por los modelos. Inicialmente, se observaron errores y ambigüedades en la clasificación de entidades, especialmente entre “adverse_drug_reactions” y “symptoms_experienced_by_patients”. Para corregir esto, se diseñó un “prompt” específico que orientaba al modelo a clasificar correctamente las entidades según definiciones claras y evitar la categorización múltiple de una misma entidad.

El “prompt” incluía una estructura en JSON para que el modelo devolviera las entidades junto con su nombre, posición inicial y final, además de ejemplos sobre cómo diferenciar correctamente las categorías según el contexto de la frase. Este enfoque permitió mejorar la precisión de los modelos no ajustados, logrando una mayor coherencia y exactitud en las respuestas, reduciendo errores y ambigüedades en la detección de entidades médicas.

Para terminar con la enumeración de las alternativas evaluadas en este trabajo, el último grupo de alternativas es el de los modelos BERT “zero-shot” conformado únicamente por:

- **GLiNER.** En el código del repositorio se identifica como “gliner”.

Este modelo ha sido implementado según las instrucciones de sus autores en [22]. En este caso, se ha hecho uso de la versión multilenguaje [23].

Por último, es de gran relevancia destacar la dificultad para mantener altos estándares en la robustez y velocidad de las respuestas de los modelos LLM debido a su aleatoriedad y dependencia de proveedores externos. Por este motivo, una implementación que se aproveche de realizar llamadas en paralelo a las APIs de los proveedores mientras se mantiene a prueba de errores siempre aporta un valor diferencial.

En este sentido, en este trabajo se ha implementado una gestión robusta y paralela para las llamadas a los proveedores de LLMs y al modelo GLiNER, contemplando los posibles errores que pueden surgir al interactuar con modelos de inteligencia artificial:

1. **Errores de Red y Conexión:** Estos pueden ocurrir debido a problemas con la conectividad a internet, limitaciones del proveedor de la API o tiempos de espera excesivos. Estos errores pueden interrumpir la comunicación con los servidores que alojan los modelos de IA.

2. **Errores de Tasa de Llamadas ("Rate Limit"):** Los proveedores de LLMs a menudo imponen límites en el número de solicitudes que se pueden realizar en un período de tiempo determinado. Superar estos límites puede resultar en errores de limitación de tasa, lo que puede bloquear temporalmente el acceso a la API.
3. **Errores Internos del Modelo:** Ocasionalmente, el modelo en sí puede encontrarse con problemas durante la ejecución, como sobrecarga del servidor, errores de procesamiento de datos o problemas internos del proveedor, que resultan en respuestas de error.
4. **Errores de Solicitud Mal Formada:** Esto ocurre cuando la solicitud enviada al modelo no cumple con los requisitos del formato o parámetros esperados por la API, resultando en fallos de procesamiento.

Para manejar estos errores y asegurar un proceso de llamadas eficiente y robusto, se han implementado las siguientes estrategias:

1. **Paralelismo de Hilos en Local:** Se ha implementado la ejecución en paralelo de las solicitudes a los modelos de IA, utilizando hilos para optimizar el rendimiento y reducir el tiempo de espera. Esto permite que múltiples solicitudes se procesen simultáneamente, mejorando la eficiencia general del sistema.
2. **Semáforo para Limitar Solicitudes Simultáneas:** Para evitar superar los límites de tasa de los proveedores y controlar el número de solicitudes concurrentes, se ha implementado un semáforo que limita el número de solicitudes simultáneas que se realizan a la API. Esto garantiza que no se excedan las restricciones del proveedor y previene errores de tasa de llamadas.
3. **Gestión de Excepciones con el decorador "Retry" de la librería "tenacity":** Para manejar las excepciones que puedan surgir durante las llamadas a los modelos, se ha utilizado el decorador "@retry", configurado con "stop=stop_after_attempt(3)" y "wait=wait_exponential(multiplier=1, min=4, max=10)". Esto significa que, en caso de un error, la solicitud se reintentará hasta tres veces, con un intervalo de espera que aumenta exponencialmente entre intentos. Esto ayuda a mitigar problemas temporales de conectividad o sobrecarga del servidor, aumentando la resiliencia del sistema.

Estas implementaciones han asegurado una gestión eficiente y fiable de las llamadas a los modelos de inteligencia artificial, minimizando la posibilidad de fallos y mejorando la robustez del proceso en general. La combinación de paralelismo, control de concurrencia y manejo de excepciones proporciona un entorno estable y optimizado para interactuar con los LLMs y el modelo GLiNER.

Obtención de Resultados y Evaluación

El proceso de obtención y análisis de resultados se encuentra documentado en la carpeta “src/lib/evaluation”, mientras que los resultados generados se almacenan en la carpeta “results”. El conjunto de datos de evaluación se ubica en la carpeta “resources/evaluation”.

La evaluación se llevó a cabo utilizando la implementación paralela descrita en la subsección anterior. Este enfoque permitió una ejecución mucho más eficiente, logrando reducir el tiempo necesario para obtener los resultados en un 78% en comparación con una implementación secuencial. Gracias a este paralelismo, fue posible procesar múltiples solicitudes simultáneamente, optimizando el uso de los recursos y acelerando significativamente la fase de evaluación.

El proceso de obtención y evaluación de resultados se llevó a cabo de manera estructurada y en varias etapas, para garantizar un análisis exhaustivo y preciso de las capacidades de los modelos en tareas de NER. Los resultados se organizaron en tres archivos principales, siguiendo este orden:

1. **ner_alternatives_results.xlsx**: En esta primera etapa, se recopilaron las respuestas en bruto generadas por los diferentes modelos al aplicarse sobre el conjunto de datos de evaluación. Estas respuestas fueron necesarias para la posterior evaluación y procesamiento.
2. **ner_alternatives_results_processed.xlsx**: Una vez obtenidas las respuestas en bruto, se procedió a procesarlas para extraer estadísticas detalladas de cada una de las respuestas generadas por los modelos. Este procesamiento incluyó la evaluación de métricas clave como precisión, “recall” y “F1-score” para cada predicción atendiendo a las entidades reconocidas, permitiendo así una comprensión más profunda del rendimiento individual de cada modelo.

Además, como las tareas de NER no solo implican el reconocimiento de entidades sino que también requieren la identificar la ubicación de tales entidades dentro del texto, se incluyeron métricas adicionales para evaluar la exactitud en la detección de las posiciones iniciales y finales de las entidades. Esto permitió analizar no solo si los modelos identificaban correctamente las entidades, sino también si eran capaces de localizar su posición exacta en el texto, lo cual es esencial para aplicaciones que dependen de la extracción precisa de información. Este análisis detallado proporcionó una visión integral del desempeño de cada modelo, tanto en términos de reconocimiento como de localización de entidades.

3. **ner_alternatives_statistics.xlsx**: Finalmente, se sintetizaron las estadísticas calculadas en el archivo anterior para generar un resumen consolidado de las estadísticas de cada modelo. Este archivo contiene los resultados agregados y las métricas generales que reflejan el desempeño de cada modelo a lo largo del proceso de evaluación. Estas

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



estadísticas ofrecen una visión comparativa y global del rendimiento de los modelos en las tareas de NER, y se reflejan en la siguiente tabla:

Nombre del modelo	Precisión	"Recall"	"F1-score"	Entidades detectadas correctamente (%)	Entidades detectadas y clasificadas correctamente (%)	Posiciones iniciales ubicadas con exactitud (%)	Posiciones finales ubicadas con exactitud (%)
"fine_tuned_gpt_4o_mini"	0,65	0,65	0,64	65,22	56,52	16,90	15,48
"fine_tuned_gpt_4o"	0,68	0,70	0,68	72,67	64,13	19,87	17,74
"fine_tuned_gpt_4o_mini_v2"	0,86	0,86	0,85	84,94	75,78	21,57	20,84
"fine_tuned_gpt_4o_v2"	0,81	0,82	0,80	81,68	75,62	30,04	30,04
"gpt_4o_mini"	0,52	0,69	0,57	68,63	39,60	11,09	6,11
"gpt_4o"	0,76	0,80	0,77	74,05	45,64	25,98	21,45
"gliner"	0,65	0,45	0,51	51,24	20,34	98,79	98,79
"sonnet_35"	0,63	0,76	0,67	76,86	67,24	23,84	20

Tabla 3: Resumen de estadísticas por modelo.

El enfoque escalonado para la obtención y análisis de resultados ha permitido llegar a las siguientes conclusiones sobre el rendimiento de los diferentes modelos de lenguaje largo y sus capacidades en tareas de NER:

- **Rendimiento General de los Modelos Ajustados:**

Los modelos ajustados mostraron un rendimiento superior en términos de precisión, "recall" y "F1-score" en comparación con los modelos no ajustados. Por ejemplo, el modelo "fine_tuned_gpt_4o_mini_v2" obtuvo un "F1-score" de 0.85, indicando una alta capacidad para identificar y clasificar correctamente las entidades médicas en el texto. El modelo "fine_tuned_gpt_4o_v2" también mostró un desempeño robusto, con un "F1-score" de 0.80, lo que sugiere que el proceso de "fine-tuning" tiene un impacto positivo significativo en la capacidad del modelo para realizar tareas de NER en el dominio de la salud.

Sin embargo, el modelo "fine_tuned_gpt_4o_v2" se destaca por estar un escalón por encima del "fine_tuned_gpt_4o_mini_v2" en términos de precisión para ubicar las

entidades. Esto sugiere que, aunque el "F1-score" global es ligeramente inferior, el "fine_tuned_gpt_4o_v2" podría ser más confiable para identificar correctamente la ubicación exacta de las entidades en los textos clínicos.

Es importante destacar la mejora constante de los LLMs a medida que se incrementa el tamaño del conjunto de datos de entrenamiento. Como se ha observado, incluso al utilizar un conjunto de datos 10 veces mayor que el recomendado por OpenAI, se logra una mejora en los resultados.

De hecho, de manera inesperada, el modelo "fine_tuned_gpt_4o" produce predicciones de menor calidad que el modelo original "gpt_4o". Esta observación, junto con los datos anteriores, sugiere que a medida que se aumenta el tamaño del modelo (como en "gpt-4o" frente a "gpt-4o mini"), puede ser necesaria una cantidad mayor de muestras de entrenamiento para alcanzar un rendimiento óptimo. Por tanto, podría ser beneficioso considerar el equilibrio entre el tamaño del modelo y el volumen de datos de entrenamiento disponibles al decidir qué modelo utilizar para tareas específicas de NER en el dominio de la salud.

- **Precisión en la Detección de Entidades:**

El porcentaje de entidades correctamente detectadas fue considerablemente alto en los modelos ajustados, con "fine_tuned_gpt_4o_mini_v2" alcanzando un 84.94%. Esto indica que el "fine-tuning" mejora la capacidad del modelo para identificar la presencia de entidades relevantes en el texto clínico.

El porcentaje de entidades correctamente detectadas y clasificadas también fue elevado para los modelos ajustados, destacando nuevamente "fine_tuned_gpt_4o_mini_v2" con un 75.78%, lo que implica que estos modelos no solo reconocen las entidades sino que también las clasifican adecuadamente.

- **Exactitud en la Ubicación de Entidades:**

En términos de localización precisa de las entidades dentro del texto, los modelos ajustados mostraron un rendimiento superior en la mayoría de los casos. Sin embargo, es destacable que el modelo GLiNER mostró una sobresaliente exactitud en la detección de las posiciones de las entidades. Esto se debe en gran medida a su preentrenamiento, que ha sido parcialmente enfocado en la localización precisa de entidades en el texto.

Por ejemplo, GLiNER logró superar a otros modelos en la coincidencia exacta de las posiciones iniciales y finales de las entidades, indicando una mayor capacidad para identificar no solo las entidades sino también su ubicación precisa. Esta habilidad es fundamental en aplicaciones que requieren una extracción exacta de información, como en la identificación de términos médicos específicos en textos clínicos.

Los modelos ajustados como “fine_tuned_gpt_4o_v2” también demostraron un buen desempeño en este aspecto, con un 30.04% de coincidencia exacta en la posición inicial y final de las entidades. No obstante, GLiNER logró una superioridad en la exactitud de localización, reforzando la importancia de un preentrenamiento especializado para mejorar este tipo de tareas.

- **Comparación con Modelos No Ajustados:**

Los modelos no ajustados, como “gpt_4o”, aunque mostraron un rendimiento razonable con un “F1-score” de 0.76 y una detección de entidades correcta en un 74.05%, quedaron por debajo de los modelos ajustados y de GLiNER. Esto resalta la importancia del “fine-tuning” y del preentrenamiento específico, como el de GLiNER, para mejorar la capacidad de los modelos en tareas de NER en contextos como el de la salud.

En resumen, los resultados obtenidos demuestran que el “fine-tuning” de los LLMs y un preentrenamiento enfocado, como el de GLiNER, tienen un impacto significativo en el rendimiento de las tareas de NER, tanto en la identificación y clasificación de entidades como en la precisión de su ubicación dentro del texto. Los modelos ajustados y especializados, como GLiNER, superan claramente a los no ajustados, lo que valida la efectividad de estos procesos para mejorar el desempeño en tareas especializadas del dominio de la salud. Estas conclusiones reafirman la importancia de adaptar y preentrenar modelos en dominios específicos para optimizar su rendimiento en aplicaciones clínicas y de investigación biomédica.

Creación de App en Streamlit

Como parte de este proyecto, se desarrolló una aplicación interactiva utilizando Streamlit para facilitar la demostración y evaluación de las diferentes alternativas NER aplicadas en el dominio de la salud. La aplicación permite a los usuarios ingresar texto médico y analizarlo utilizando distintos modelos, tanto ajustados como no ajustados, para identificar y clasificar entidades médicas como reacciones adversas a medicamentos (ADR), enfermedades, medicamentos, hallazgos clínicos y síntomas.

Es **importante** tener en cuenta que, para hacer uso de esta demo, se debe de crear en el repositorio clonado un archivo “.env” con las “API keys” propias del usuario de OpenAI [24] y Anthropic [25]. De lo contrario, la aplicación no funcionará.

La interfaz de usuario de la aplicación es sencilla y directa. Presenta una sección de entrada donde los usuarios pueden escribir o pegar el texto que desean analizar. Tras pulsar el botón “Execute”, el texto se procesa simultáneamente con las diferentes alternativas de modelos de NER, incluyendo:

- **“Fine-tuned GPT-4o Large”:** “fine_tuned_gpt_4o_v2”

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



- **“Fine-tuned GPT-4o Small”**: "fine_tuned_gpt_4o"
- **“GPT-4o”**: "gpt_4o"
- **“GPT-4o Mini”**: "gpt_4o_mini"
- **“Fine-tuned GPT-4o Mini Large”**: "fine_tuned_gpt_4o_mini_v2"
- **“Fine-tuned GPT-4o Mini Small”**: "fine_tuned_gpt_4o_mini"
- **“Sonnet 3.5”**: "sonnet_35"
- **“GLiNER”**: "gliner"

Cada uno de estos modelos se muestra como una tarjeta en la interfaz, y los resultados generados por cada modelo se visualizan de manera separada, lo que permite comparar fácilmente el desempeño y la calidad de las respuestas de cada modelo.

La aplicación también incluye una descripción de las categorías de entidades que se identifican, proporcionando al usuario información contextual sobre las etiquetas utilizadas, como “adverse drug reactions”, “disease”, “drug”, “finding”, y “symptom”. Esto facilita la comprensión de los resultados y permite una evaluación más intuitiva del rendimiento de cada modelo.

La creación de esta aplicación con Streamlit proporciona una herramienta poderosa y accesible para interactuar con los modelos de NER desarrollados y evaluados en este proyecto. Permite a los usuarios explorar de forma práctica cómo funcionan las distintas alternativas de NER, comparar resultados en tiempo real y obtener una experiencia directa del impacto del “fine-tuning” y la capacidad de diferentes modelos en la identificación y clasificación de entidades médicas. Además, la aplicación es fácilmente extensible, lo que permite la integración de nuevos modelos y características según sea necesario.

“Dockerización”

Se ha propuesto una “dockerización” inicial del proyecto, descrita en el archivo “Dockerfile” del repositorio, la cual incluye las siguientes características:

- **Variables de entorno**: La imagen Docker incluye las variables de entorno definidas en el archivo ".env" del repositorio, lo que permite una configuración flexible y segura del entorno de ejecución.
- **Dependencias**: Se utiliza una lista de dependencias específica, "requirements_linux.txt", la cual excluye la librería "pywin32" para evitar errores, ya que esta es solo compatible con sistemas Windows.
- **Ejecución automática**: Al crear un contenedor a partir de la imagen generada, se ejecuta el comando “streamlit run src/app/app.py”. Esto inicia automáticamente la aplicación en el navegador, facilitando su acceso y uso inmediato.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



4.3 Recursos requeridos

Para la ejecución de este Trabajo de Fin de Máster (TFM) se han utilizado los siguientes recursos:

- **Un ordenador personal con acceso a internet:** Necesario para la realización de todas las etapas del proyecto, desde la investigación hasta el desarrollo y evaluación de los modelos.
- **Cuenta de OpenAI con dinero ingresado y una “API key”:** Utilizada para acceder a los modelos de lenguaje GPT y realizar el “fine-tuning” necesario para el proyecto.
- **Cuenta de Anthropic con dinero ingresado y una “API key”:** Requerida para el acceso y utilización del modelo Claude 3.5 Sonnet durante la evaluación y comparación con otros modelos.
- **Modelo GLiNER:** Descargado a través de la librería “gliner” para su utilización como modelo de referencia en tareas de NER dentro del dominio de la salud.
- **Mentorización y apoyo de mi compañero de trabajo:** Colaboración esencial para la realización del proyecto, por lo cual estoy muy agradecido.
- **OpenAI “Fine-tuning UI”:** Herramienta utilizada para crear trabajos de “fine-tuning” con los modelos de OpenAI, facilitando el proceso de entrenamiento con los datos clínicos.
- **Docker:** Empleado para la creación de contenedores que faciliten el posible despliegue futuro de la herramienta desarrollada.
- **Streamlit:** Herramienta utilizada para el desarrollo de una demo del proyecto, permitiendo a los usuarios interactuar con las diferentes alternativas NER analizadas.
- **Resto de librerías externas:** Enumeradas en el archivo 'requirements.txt' del proyecto, necesarias para la implementación y funcionamiento del modelo y de la aplicación.

Estos recursos han sido esenciales para llevar a cabo cada etapa del proyecto, desde la experimentación y desarrollo hasta la implementación y evaluación de los modelos de lenguaje largo ajustados para tareas de NER en el ámbito de la salud.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



4.4 Presupuesto

A continuación, se presenta el presupuesto total del proyecto, incluyendo las horas de trabajo invertidas, el equipo técnico utilizado, el software y otros posibles costos asociados.

Tipo de coste	Valor	Comentarios
Horas de trabajo en el proyecto	240 horas	Incluye el tiempo invertido en investigación, desarrollo, pruebas y documentación del proyecto. Estimación basada en un promedio de 8 horas diarias durante 30 días laborables.
Equipo técnico utilizado	600 €	Coste estimado de un ordenador personal utilizado para todo el proceso de desarrollo e implementación del proyecto.
Software utilizado	100 €	La suscripción a “Pro Cursor IDE” han sido 20 € al mes durante 2 meses. Agiliza el desarrollo desde el entorno de desarrollo integrado (IDE) gracias al autocompletado de código que incorpora basado en los mejores LLMs del momento. La suscripción a “ChatGPT” han sido 20 € al mes durante 2 meses. Utilizada para asistencia en cuestiones más complejas durante el desarrollo que el asistente de código de Cursor no podía atender. El gasto aproximado de la API de OpenAI y su “Fine-tuning UI” son 15€. El gasto aproximado de la API de Anthropic son 5€.
Estudios e informes	€	No se ha tenido que adquirir ningún informe adicional de consultoría o revista de investigación.
Materiales empleados	€	No se han utilizado materiales físicos adicionales, como material de laboratorio o sensores.
Total	700 € + Horas de trabajo	

Tabla 4: Presupuesto desglosado del proyecto.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



4.5 Viabilidad

Este proyecto presenta una alta viabilidad tanto desde el punto de vista económico como técnico. A continuación, se analiza la relación coste/beneficio y la sostenibilidad a futuro del trabajo realizado.

Análisis de Viabilidad Económica (Relación Coste/Beneficio)

El coste total del proyecto, estimado en 700 € más las horas de trabajo invertidas, se ha mantenido en un rango razonable gracias a la optimización de los recursos y la utilización de herramientas y servicios que ofrecen modelos preexistentes, como Anthropic y OpenAI, esta última con posibilidad de “fine-tuning”. La inversión en software, como las suscripciones a “Pro Cursor IDE” y “ChatGPT”, ha proporcionado un soporte crucial en el proceso de desarrollo, permitiendo acelerar y mejorar la eficiencia de la implementación del proyecto.

En términos de beneficios, el desarrollo de un modelo de lenguaje largo ajustado para tareas de NER en el ámbito de la salud tiene un potencial impacto positivo significativo. La capacidad de automatizar la identificación y clasificación de entidades médicas en grandes volúmenes de datos clínicos puede facilitar la toma de decisiones en entornos clínicos, mejorar la eficiencia en la gestión de datos y aportar herramientas útiles para la investigación biomédica. Por tanto, la inversión inicial es justificable y puede generar un alto retorno de inversión (ROI) si se integra y utiliza en sistemas de salud y aplicaciones clínicas.

Análisis de Sostenibilidad a Futuro

Desde la perspectiva de sostenibilidad, el proyecto se ha desarrollado utilizando tecnologías y herramientas que facilitan su despliegue y escalabilidad. La utilización de Docker para su contenedorización hace que la solución sea fácilmente portable y adaptable a diferentes entornos. Esto permite una integración sencilla en sistemas de salud existentes o futuras plataformas de análisis clínico.

Además, el modelo ajustado y la infraestructura desarrollada pueden seguir siendo actualizados y mejorados con nuevos datos clínicos, lo que asegura que la solución se mantenga relevante y efectiva a lo largo del tiempo. La posibilidad de realizar ajustes finos adicionales con nuevos conjuntos de datos permitirá que el modelo evolucione y se adapte a las necesidades cambiantes del dominio médico.

También, cabe destacar que a medida que los LLMs vayan incrementando su calidad se podrá modificar el modelo empleado por la herramienta con un simple cambio en el código y las futuras tareas de NER podrán ser más precisas. El último detalle que se debe tener en cuenta es el precio de cada llamada a los LLMs: irá disminuyendo con la evolución de los modelos y la aparición de nuevas alternativas, incluyendo las de código abierto.

En resumen, la viabilidad económica y la sostenibilidad futura del proyecto son favorables, dado el bajo coste relativo y el alto potencial de impacto y beneficio en el ámbito de la salud. La metodología utilizada garantiza que la solución pueda ser integrada, utilizada y ampliada, lo que refuerza la pertinencia y utilidad de este trabajo en contextos reales.

4.6 Resultados del proyecto

Conforme a los objetivos específicos planteados, se han obtenido una serie de resultados finales que demuestran el cumplimiento y la eficacia de las estrategias implementadas durante el desarrollo de este proyecto.

El “fine-tuning” de los modelos GPT-4o en sus diferentes variantes se realizó con éxito. Los modelos ajustados demostraron un rendimiento significativamente mejorado en las tareas de reconocimiento de entidades nombradas (NER) en el ámbito de la salud, con métricas como precisión, “recall” y “F1-score” notablemente superiores en comparación con sus versiones no ajustadas. Por ejemplo, el modelo “fine_tuned_gpt_4o_mini_v2” alcanzó un “F1-score” de 0.85, indicando una alta capacidad para identificar y clasificar correctamente las entidades médicas.

Los modelos sin “fine-tuning”, como GPT-4o y Claude 3.5 Sonnet, se implementaron utilizando LangChain y técnicas de “prompting” personalizadas para mejorar su rendimiento. Aunque mostraron un desempeño razonable, los modelos ajustados, así como GLiNER, destacaron por su mayor exactitud y precisión. GLiNER, en particular, demostró ser excepcionalmente efectivo en la ubicación precisa de las entidades, gracias a su preentrenamiento especializado en la detección de posiciones.

Se desarrolló una aplicación interactiva en Streamlit que permite a los usuarios analizar texto médico utilizando las diferentes alternativas de modelos NER. La aplicación facilita la comparación de resultados entre los modelos ajustados, no ajustados y GLiNER, proporcionando una herramienta práctica para evaluar y comprender las capacidades de cada enfoque. La interfaz es intuitiva y permite realizar análisis en tiempo real, lo que aporta valor tanto para la demostración como para la evaluación de los modelos.

Se implementó con éxito la gestión paralela de llamadas a los modelos, incluyendo un semáforo para limitar las solicitudes simultáneas y técnicas de reintento para gestionar posibles errores en las llamadas a la API. Esta optimización redujo el tiempo de obtención de resultados en un 78% en comparación con una implementación secuencial, lo que demuestra la eficacia de las estrategias implementadas para manejar las tareas de NER de manera eficiente.

Durante el desarrollo del proyecto, uno de los cambios más notables fue la necesidad de utilizar la interfaz de “fine-tuning” de OpenAI debido a las restricciones de acceso a la API para usuarios con un nivel inferior al 4. Aunque esto limitó en cierta medida la flexibilidad en la personalización del proceso de “fine-tuning”, se logró compensar esta limitación mediante el uso de la “fine-

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



tuning UI” y la implementación de técnicas de “prompting” para los modelos no ajustados. Otro de los cambios fue la implementación de mecanismos que asegurasen la obtención de respuestas de manera paralela y robusta.

El plan de pruebas se centró en evaluar la capacidad de los modelos para identificar y clasificar entidades médicas en textos clínicos. Las pruebas incluyeron la evaluación de métricas estándar de NER y la validación de la exactitud en la detección de la posición de las entidades. Los resultados mostraron que los modelos ajustados y GLiNER cumplen con los requisitos esperados, superando a los modelos no ajustados en la mayoría de las métricas evaluadas.

Los resultados del proyecto confirman la efectividad del “fine-tuning” en modelos de lenguaje largo para tareas de NER en el dominio de la salud. La aplicación desarrollada en Streamlit y las optimizaciones implementadas ofrecen una solución práctica y eficiente para el análisis de texto médico, facilitando la identificación precisa de entidades clínicas. En definitiva, este trabajo proporciona una base sólida para futuras investigaciones y aplicaciones en el ámbito del procesamiento del lenguaje natural en salud.

Capítulo 5. CONCLUSIONES

5.1 Conclusiones del trabajo

El objetivo general de este proyecto fue ajustar y evaluar modelos de lenguaje largo (LLMs), como GPT-4o, para realizar tareas de reconocimiento de entidades nombradas (NER) en el ámbito de la salud. Los resultados obtenidos demuestran que el “fine-tuning” de estos modelos mejora significativamente su capacidad para identificar y clasificar entidades médicas en textos clínicos, cumpliendo así con los objetivos planteados inicialmente. Además, la integración y evaluación de otros modelos, como GLiNER, permitió establecer un punto de referencia y destacó la importancia de preentrenamientos especializados para tareas de NER.

La creación de una aplicación interactiva en Streamlit también fue un resultado clave del proyecto, ya que proporciona una herramienta práctica para analizar y comparar las capacidades de diferentes modelos de NER en tiempo real. Este desarrollo, junto con la optimización de los procesos de evaluación y la implementación de técnicas de “prompting”, contribuye a una mejor comprensión de las aplicaciones y limitaciones de los modelos de lenguaje largo en el dominio de la salud.

5.2 Conclusiones personales

La oportunidad de trabajar con modelos de lenguaje avanzados y explorar su potencial en tareas especializadas de NER me ha permitido profundizar en un área de investigación de gran relevancia y actualidad. He comprendido la importancia del “fine-tuning” y de las técnicas de “prompting” para mejorar el rendimiento de los modelos en tareas específicas, y cómo cada detalle en la configuración y evaluación de los modelos puede impactar en los resultados finales.

Una de las lecciones más valiosas fue la necesidad de adaptarse a las limitaciones y desafíos encontrados a lo largo del proyecto. La restricción de acceso a ciertas funcionalidades de la API de OpenAI y la necesidad de emplear la “fine-tuning UI”, así como muchos otros baches el desarrollo de este trabajo me enseñaron a ser flexible y a buscar alternativas que permitieran continuar avanzando hacia los objetivos planteados. También aprendí a aprovechar al máximo las herramientas disponibles, como LangChain y Streamlit, para implementar y presentar los resultados de manera efectiva.

Este proyecto no solo ha sido una oportunidad para aplicar y ampliar mis conocimientos en procesamiento del lenguaje natural y aprendizaje automático, sino que también me ha permitido la posibilidad de contribuir, aunque sea de forma modesta, a la mejora de las herramientas de análisis y gestión de información clínica me motiva a seguir explorando y desarrollando soluciones innovadoras en este campo.

Capítulo 6. FUTURAS LÍNEAS DE TRABAJO

El desarrollo de este proyecto ha abierto diversas oportunidades para futuras líneas de investigación y trabajo, que podrían expandir y mejorar aún más los resultados obtenidos. A continuación, se destacan algunas de las áreas más prometedoras para continuar y profundizar en este ámbito:

6.1 Ampliación del Conjunto de Datos

Una de las principales áreas de mejora es la ampliación y diversificación del conjunto de datos utilizado para el “fine-tuning” de los modelos. Incorporar un conjunto de datos más extenso y diverso, que incluya una variedad más amplia de textos clínicos y de diferentes fuentes, podría ayudar a mejorar la capacidad de los modelos para generalizar a situaciones del mundo real. Además, la inclusión de datos multilingües permitiría explorar la aplicabilidad de los modelos en contextos internacionales, donde los textos clínicos pueden estar en diferentes idiomas.

6.2 Experimentación con Técnicas de Transfer Learning

Otra línea de trabajo interesante es la exploración de técnicas de “transfer learning” más avanzadas. Si bien este proyecto utilizó el “fine-tuning” tradicional, existe la posibilidad de investigar enfoques como el “few-shot learning” o el “zero-shot learning” para ver cómo estos pueden complementar o incluso mejorar los resultados obtenidos. Estas técnicas podrían ser particularmente útiles para abordar situaciones donde los datos etiquetados son limitados o para adaptar el modelo a nuevas tareas de NER sin requerir un “fine-tuning” extenso.

6.3 Integración y Evaluación en Entornos Clínicos Reales

Una siguiente etapa lógica sería la integración de los modelos ajustados en entornos clínicos reales para evaluar su desempeño en la práctica. Esto podría implicar la implementación de los modelos en sistemas de gestión de registros médicos electrónicos (EHR) para automatizar la extracción de información relevante o en sistemas de soporte a la toma de decisiones clínicas. La evaluación de los modelos en un entorno real permitiría no solo validar su aplicabilidad y efectividad, sino también identificar posibles mejoras y adaptaciones necesarias para su uso en la práctica diaria.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



6.4 Desarrollo de un “Pipeline” de “Fine-tuning” Automatizado

Dada la limitación encontrada con respecto al acceso a la API de “fine-tuning”, otra línea de trabajo futura podría ser el desarrollo de una secuencia de procesos o “pipeline” de “fine-tuning” completamente automatizado. Esto podría incluir la construcción de una herramienta que facilite la preparación y el “fine-tuning” de los modelos en diferentes conjuntos de datos, con la capacidad de gestionar automáticamente las llamadas a la API, la evaluación y el almacenamiento de resultados. Una herramienta de este tipo permitiría agilizar y escalar el proceso de “fine-tuning” para diferentes dominios y aplicaciones.

6.5 Mejora de la Aplicación Interactiva

Aunque la aplicación desarrollada en Streamlit proporciona una herramienta útil para la evaluación y comparación de los modelos, existe la posibilidad de expandir y mejorar esta aplicación. Por ejemplo, se podría añadir una funcionalidad para visualizar de forma interactiva las entidades reconocidas en el texto, o para permitir a los usuarios ajustar los parámetros del modelo en tiempo real. Además, se podría trabajar en la implementación de la aplicación en un entorno web más robusto, permitiendo su acceso y uso por parte de profesionales de la salud e investigadores de manera más amplia.

6.6 Investigación sobre la Interpretabilidad y Explicabilidad de los Modelos

Finalmente, una línea de investigación crucial para el uso de modelos de lenguaje en entornos clínicos es la interpretabilidad y explicabilidad de los modelos. Dado que las decisiones médicas pueden tener consecuencias críticas, es fundamental que los modelos de NER no solo sean precisos, sino también interpretables. Futuras investigaciones podrían centrarse en desarrollar métodos y herramientas que permitan comprender mejor cómo y por qué los modelos identifican ciertas entidades, ayudando a construir confianza en el uso de estas herramientas en la práctica clínica.

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



6 REFERENCIAS

- [1] N. T. P. H. T. C. Urchade Zaratiana, «GLiNER,» 14 11 2023. [En línea]. Available: <https://arxiv.org/abs/2311.08526>.
- [2] «GPT-4o mini: advancing cost-efficient intelligence,» OpenAI, 18 06 2024. [En línea]. Available: <https://openai.com/index/gpt-4o-mini-advancing-cost-efficient-intelligence/>.
- [3] Streamlit, Snowflake Inc., [En línea]. Available: <https://streamlit.io/>.
- [4] I. H. Roldán, «Github - ner_alternatives,» [En línea]. Available: https://github.com/ivanhernandezroldan/ner_alternatives.
- [5] W. Y. S. K. D. K. S. K. C. H. S. J. K. Jinhyuk Lee, «BioBERT: a pre-trained biomedical language representation model for biomedical text mining,» 18 10 2019. [En línea]. Available: <https://arxiv.org/abs/1901.08746>.
- [6] J. A. R. R. Kexin Huang, «ClinicalBERT: Modeling Clinical Notes and Predicting Hospital Readmission,» 29 11 2020. [En línea]. Available: <https://arxiv.org/abs/1904.05342>.
- [7] OpenAI, «Hello GPT-4o,» 13 05 2024. [En línea]. Available: <https://openai.com/index/hello-gpt-4o/>.
- [8] ANTHROPIC, «Claude 3.5 Sonnet,» 21 06 2024. [En línea]. Available: <https://www.anthropic.com/news/claude-3-5-sonnet>.
- [9] «Docker,» Docker, [En línea]. Available: <https://www.docker.com/>.
- [10] «Fine-Tuning LLMs : Overview, Methods, and Best Practices,» TURING, [En línea]. Available: <https://www.turing.com/resources/finetuning-large-language-models>. [Último acceso: 25 05 2024].
- [11] « LMSYS Chatbot Arena Leaderboard,» LMSYS, [En línea]. Available: <https://lmarena.ai/>. [Último acceso: 25 06 2024].
- [12] NielsRogge, «Fine-tuning BERT for named-entity recognition,» [En línea]. Available: <https://colab.research.google.com/github/NielsRogge/Transformers->

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



Tutorials/blob/master/BERT/Custom_Named_Entity_Recognition_with_BERT_only_first_wordpiece.ipynb. [Último acceso: 15 06 2024].

[13 «Fine-tuning - Preparing your dataset - Example format,» OpenAI, [En línea]. Available:
] <https://platform.openai.com/docs/guides/fine-tuning/example-format>. [Último acceso:
10 07 2024].

[14 «Structured Outputs,» OpenAI, [En línea]. Available:
] <https://platform.openai.com/docs/guides/structured-outputs/introduction>. [Último
acceso: 10 07 2024].

[15 «Fine-tuning - Fine-tuning examples,» OpenAI, [En línea]. Available:
] <https://platform.openai.com/docs/guides/fine-tuning/fine-tuning-examples>. [Último
acceso: 10 07 2024].

[16 U. O. Stubbs A, «Annotating longitudinal clinical narratives for de-identification: The 2014
] i2b2/UTHealth corpus,» J Biomed Inform., PII: S1532-0464(15)00182-3. DOI:
10.1016/j.jbi.2015.07.020., 2015 Aug 28.

[17 «n2c2 NLP Research Data Sets,» DBMI Data Portal, [En línea]. Available:
] <https://portal.dbmi.hms.harvard.edu/projects/n2c2-nlp/>. [Último acceso: 12 06 2024].

[18 S. J. M. J. A. J. K. M. O. W. C. O. Karimi, «CSIRO Adverse Drug Event Corpus (CADEC),» CSIRO
] , 18 10 2013. [En línea]. Available: <https://data.csiro.au/collection/csiro:10948v3>.

[19 «Fine-tuning - Preparing your dataset - Upload a training file,» OpenAI, [En línea]. Available:
] <https://platform.openai.com/docs/guides/fine-tuning/upload-a-training-file>. [Último
acceso: 15 07 2024].

[20 «Fine-tuning UI,» OpenAI, [En línea]. Available: <https://platform.openai.com/finetune/>.
] [Último acceso: 26 07 2024].

[21 «Structured Output,» LangChain, [En línea]. Available:
] https://python.langchain.com/v0.1/docs/modules/model_io/chat/structured_output/.
[Último acceso: 02 08 2024].

[22 N. T. P. H. T. C. Urchade Zaratiana, «GitHub GLiNER,» [En línea]. Available:
] <https://github.com/urchade/GLiNER/tree/main>. [Último acceso: 03 08 2024].

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán



[23 «Hugging Face - gliner_multi-v2.1,» urchade, [En línea]. Available:
] https://huggingface.co/urchade/gliner_multi-v2.1. [Último acceso: 03 08 2024].

[24 «Profile - User API keys,» OpenAI, [En línea]. Available:
] <https://platform.openai.com/settings/profile?tab=api-keys>. [Último acceso: 20 08 2024].

[25 «Settings - API keys,» Anthropic, [En línea]. Available:
] <https://console.anthropic.com/settings/keys>. [Último acceso: 20 08 2024].

Ajuste de los Modelos Largos de Lenguaje (Ej. GPT)
para tareas de Named Entity Recognition (NER)
específicas del dominio de la salud

Iván Hernández Roldán

